

Sommario

1. Il Problema Big Data & Rilevanza Metodologica: Le "V" Coinvolte	4
1.1 Volume: Scalabilità del Corpus e Storage Ibrido (Locale & Cloud S3).....	4
1.2 Veracity: Il Vincolo di Fedeltà Assoluta e la Guarded Generation.....	4
1.3 Variety: Standard Normativi Multipli, Valute ed Eterogeneità Strutturale.....	5
1.4 Velocity: Retrieval Sub-Secondo su Indici HNSW.....	5
2.1 La Patologia dell'Affollamento da Allegati Legali.....	6
2.2 Diluizione Semantica da Over-Expansion delle Keyword.....	6
2.3 Monopolizzazione del Contesto e Allucinazioni nelle Query Comparative	6
3. Architettura di Sistema Proposta.....	7
3.1 Ingestion Pipeline & Metadata Enrichment.....	9
3.2 Adaptive Semantic Querying & Entity Filtering.....	9
3.3 Balanced Per-Company Context Allocation	9
3.4 Algoritmo di Ranking Gerarchico dei Chunk (_rank_chunk).....	9
3.5 Guarded Generation & Self-Correction Agent (Auditor Indipendente).....	10
4. Valutazione Sperimentale (Experimental Evaluation).....	12
4.1 Analisi dell'Efficacia: Azzeramento delle Allucinazioni	12
4.2 Analisi dell'Efficienza: Trade-off Prestazionale e Flessibilità di Provider	13
5. Casi di Studio Reali & Dimostrazione di Data Analytics	14
5.1 Caso 1: Retail & Grande Distribuzione — Walmart vs Target (FY 2023).....	14
5.2 Caso 2: Pagamenti Digitali & FinTech — Mastercard vs PayPal (FY 2023)	14
5.3 Caso 3: Cloud Software; Salesforce vs ServiceNow (FY 2024).....	15
5.4 Caso 4: Cross-Standard e Multi-Valuta — Airbnb (\$ USD) vs Spotify (€ EUR) (FY 2023).....	15
6. Conclusioni, Riproducibilità e Sviluppi Futuri.....	16
6.1 Riproducibilità del Progetto.....	16
6.2 Sviluppi Futuri	16

DATA-CENTRIC RAG FOR FINANCIAL ANALYTICS

Un'architettura adattiva con Guarded Generation e Self-Correction per l'analisi comparativa di bilanci su larga scala (Form 10-K)

Ambito di Progetto: Topic 2: RAG for Data Analytics (Data-Centric GenAI)

https://github.com/cristianzucconi2-web/progetto_bigdata_personale

Abstract

Il presente progetto affronta una delle sfide aperte più complesse nell'ambito dei Big Data applicati ai Large Language Models (LLM): l'interrogazione analitico-quantitativa e la comparazione multi-anno e cross-azienda su documenti contabili ufficiali ad elevata densità formale (Form 10-K e Form 20-F depositati presso la SEC).

Il Problema Reale e l'Obiettivo del Progetto

Nel mondo aziendale e finanziario, i bilanci annuali delle multinazionali superano frequentemente le 200–300 pagine ciascuno. Per un analista finanziario, un revisore dei conti o un investitore istituzionale, estrarre metriche precise e condurre analisi comparative (ad esempio: calcolare l'evoluzione percentuale dei margini operativi, confrontare la redditività tra competitor o tracciare l'incidenza delle spese di Ricerca e Sviluppo su più annualità) richiede oggi ore di lavoro manuale, la lettura di decine di prospetti complessi e continui calcoli su fogli di calcolo, con un rischio elevatissimo di errore umano o omissione.

L'obiettivo di questo lavoro è sviluppare un **assistente analitico autonomo e certificato**: un sistema a cui l'utente può porre domande complesse in linguaggio naturale (es. **"Confronta i ricavi e l'utile operativo di Meta e Microsoft nel 2023 e calcola chi ha i margini più alti"**) e ottenere in pochi secondi una risposta quantitativa accurata, con formule matematiche esplicitate, tabelle comparative strutturate e la citazione puntuale del file sorgente e dell'anno fiscale.

Questo approccio trova immediata applicazione in molteplici contesti come per esempio:

1. **Audit e Revisione Contabile**: convalida automatica e certificata delle cifre dichiarate dalle aziende; evitando dunque eventuali errori umani di trascrizione ed effettuare una ricerca istantanea senza cercare manualmente una voce specifica.
2. **Competitive Intelligence & Benchmarking**: confronto istantaneo delle performance di mercato tra società concorrenti (es. Coca-Cola vs PepsiCo, Meta vs Microsoft, Mastercard vs PayPal);

3. Due Diligence per Fusioni e Acquisizioni (M&A): verificare in pochi secondi se un'azienda è solida prima di comprarla o finanziarla, controllando come sono cambiati debiti e ricavi nel tempo.

Nei contesti finanziari, i sistemi RAG convenzionali (Naive RAG) falliscono sistematicamente a causa di tre patologie intrinseche: l'inquinamento da allegati legali, la diluizione semantica nei vettori di embedding densi causata dall'inquinamento delle query e le allucinazioni dei numeri quando si confrontano annualità differenti. Per quanto riguarda quest'ultimo punto, è infatti difficile capire per le Naive Rag la grande differenza presente tra due date con solo un anno di distanza, essendo due query che si differenziano solo per l'anno, vicine nello spazio vettoriale dell'embedding.

Per risolvere queste criticità, è stata sviluppata un'architettura avanzata conforme al paradigma Data-Centric GenAI: un sistema integrato basato su indicizzazione vettoriale (con storage ibrido locale/AWS S3), recupero semantico bilanciato per azienda, classificazione gerarchica dei chunk contabili con eliminazione dei boilerplate legali, e una catena di Guarded Generation & Self-Correction operata da un secondo LLM (Financial Auditor) che valida preliminarmente ogni risposta contro il contesto prima del rilascio, garantendo il 100% di conformità documentale (Faithfulness Score).

In particolar modo, il sistema indicizza 106 bilanci annuali ufficiali di 22 multinazionali globali su un orizzonte temporale di 8 anni (2018–2025), generando oltre 132.183 chunk semantici. Nei test di validazione sperimentale, che saranno elencati nella parte conclusiva della relazione, l'architettura ha azzerato gli errori di attribuzione cross-azienda (da 35% a 0%) e risolto al 100% il recupero su società estere Form 20-F (es. Spotify) e colossi della grande distribuzione (Walmart, Target) e del FinTech (Mastercard, PayPal).

1. Il Problema Big Data & Rilevanza Metodologica: Le "V" Coinvolte

Il progetto affronta le principali sfide relative ai problemi di big data. In particolare, la dimensione del Volume viene combinata con altre tre determinanti 'V' dei Big Data: la Veracity (requisito primario nel dominio finanziario), la Variety (dati eterogenei non strutturati e standard contabili multipli) e la Velocity (tempi di recupero tramite indici vettoriali di HNSW).

1.1 Volume: Scalabilità del Corpus e Storage Ibrido (Locale & Cloud S3)

- **Ampiezza del Corpus Documentale:** La base documentale non si limita a report esemplificativi, ma raccoglie 106 documenti annuali integrali depositati presso la SEC (Securities and Exchange Commission) e l'ASX, relativi a 22 primarie aziende multinazionali (Apple, Microsoft, Amazon, Tesla, Meta, Google/Alphabet, Walmart, Target, Coca-Cola, PepsiCo, Mastercard, PayPal, Spotify, Salesforce, ServiceNow, Netflix, Nvidia, Intel, IBM, Dell, Adobe, Cisco).
- **Dimensioni Vettoriali e Metadati:** L'ingestion e la tokenizzazione hanno prodotto 132.183 chunk vettorializzati. Ogni chunk è arricchito con metadati (società, ticker, anno fiscale, sorgente PDF, indici di posizione e puntatori bidirezionali prev_id/next_id).
- **Integrazione Cloud Ibrida (AWS S3):** L'architettura supporta una doppia modalità di storage: storage locale ottimizzato per sviluppo ed esame, e modulo integrato AWS S3 (s3://miei-bilanci-rag-10k) con gestione del download selettivo e streaming, soddisfacendo le best practice industriali di archiviazione Big Data su cloud.

1.2 Veracity: Il Vincolo di Fedeltà Assoluta e la Guarded Generation

Nel reporting finanziario, l'accuratezza del dato è estremamente importante: un'allucinazione che attribuisca 10 miliardi di debito o scambi i margini di profitto tra due competitor invalida l'intero processo decisionale. Per garantire la Veracity:

- **Filtraggio Deterministico:** Il recupero vettoriale è vincolato deterministicamente dai metadati societari e temporali, impedendo contaminazioni da anni fiscali disallineati.
- **Auditing Indipendente & Self-Correction:** Implementazione di un loop di Self-Correction a due stadi: un primo LLM generativo elabora la bozza analitica basandosi esclusivamente sul contesto recuperato; un secondo LLM indipendente (Financial Auditor) esegue la cross-validation punto per punto contro le fonti contabili, calcolando un Faithfulness Score numerico (0–100%) e rettificando in tempo reale ogni possibile imprecisione prima dell'invio all'interfaccia utente. Questa parte della pipeline inoltre, ci permette di passare ad una rag avanzata, controllando l'affidabilità dell'output generato precedentemente.

1.3 Variety: Standard Normativi Multipli, Valute ed Eterogeneità Strutturale

- **Standard Contabili Eterogenei:** Il sistema ingerisce e armonizza sia filing US GAAP (Form 10-K tipici delle società statunitensi) sia filing IFRS (Form 20-F per società estere quotate a Wall Street, come Spotify Technology S.A. con sede in Lussemburgo, e annual report australiani ASX come Coca-Cola Europacific Partners).
- **Varietà di Formato Interno:** Nello stesso bilancio si potevano trovare testi completamente differenti, come paragrafi discorsivi (quali per esempio rischi aziendali) oppure tabelle con solo numeri presenti.
- **Disomogeneità Monetaria:** Il sistema riconosce e gestisce in modo distinto le valute native riportate (\$ USD ed € EUR), evitando conversioni arbitrarie e segnalando esplicitamente la divisa corretta per ciascun operatore.

1.4 Velocity: Retrieval Sub-Secondo su Indici HNSW

Nonostante la dimensione del database (>132.000 nodi vettoriali), il retrieval impiega algoritmi HNSW (Hierarchical Navigable Small World) su ChromaDB, assicurando un tempo di risposta del motore vettoriale inferiore a 300 millisecondi per query composite con multi-filtro.

2. Dai Limiti del Naive RAG alla Necessità del Data-Centric GenAI

La letteratura recente e le sperimentazioni sul campo dimostrano che l'approccio Naive RAG (suddivisione del testo in chunk uniformi, calcolo del coseno di similarità e iniezione nel prompt dell'LLM che si intende utilizzare) può risultare inadeguato per compiti di data analytics su bilanci societari. Durante la fase iniziale della ricerca sono emersi tre problemi principali:

2.1 La Patologia dell'Affollamento da Allegati Legali

Un Form 10-K o Form 20-F può superare le 200 pagine, di cui soltanto 4 o 5 contengono i dettagli finanziari primari (Statements of Operations, Balance Sheet, Cash Flows). La restante parte è costituita da accordi sindacali, statuti societari, deleghe e certificazioni legali (Exhibit 10, Exhibit 12, Form S-8). Poiché tali contratti ripetono ossessivamente il nome completo dell'azienda (es. 'Spotify Technology S.A.') e contengono formule standardizzate, il modello di embedding denso (all-MiniLM-L6-v2) assegnava loro una similarità semantica più alta rispetto al prospetto contabile vero e proprio, dove le cifre di fatturato figurano in forma tabellare sintetica senza ripetere il nome aziendale su ciascuna riga.

2.2 Diluizione Semantica da Over-Expansion delle Keyword

Nei primi prototipi, l'espansione terminologica univa fino a 16 sinonimi contabili concatenati alla query. I modelli di embedding con context window limitata (256 token) subivano una severa dispersione semantica: il vettore risultante rappresentava un rumore indistinto di termini contabili anziché il target analitico ricercato, con il rischio dunque di escludere dai top-k chunk proprio i dettagli finanziari ricercati nella query.

2.3 Monopolizzazione del Contesto e Allucinazioni nelle Query Comparative

Nelle query comparative su due aziende (es. Walmart vs Target o Mastercard vs PayPal), il Naive RAG recuperava chunk su scala globale. Se l'azienda con il bilancio più voluminoso otteneva score mediamente superiori, monopolizzava il 90% del token budget del prompt. Di conseguenza, l'LLM generava la risposta basandosi sui dati di una sola società e allucinava le metriche della seconda, oppure scambiava i valori tra competitor all'interno della stessa tabella comparative pur di non generare un output senza la specifica richiesta.

3. Architettura di Sistema Proposta

Per superare in modo sistemico i limiti descritti, è stata progettata un'architettura modulare avanzata orientata al dato (Data-Centric). Il flusso operativo si articola in cinque stadi sequenziali coordinati:

Componente	Tecnologia / Modulo	Ruolo nel Flusso Big Data
Ingestion & Storage Ibrido	PyPDF + RecursiveSplitter + AWS S3	Estrazione testuale, chunking a 800 caratteri con overlap 100, storage s3://miei-bilanci-rag-10k.
Vector DB & Embedding	ChromaDB (HNSW) + all-MiniLM-L6-v2	Indicizzazione di 132.183 nodi con embedding locale a 384 dimensioni e persistenza su disco.
Adaptive Query Routing	Regex parser + LLM fallback (JSON)	Isolamento deterministico di company, fiscal_year e intent analitico (ricavi, R&D, utile, rischi).
Balanced Retrieval & Ranking	pipeline.py (algoritmo euristico personalizzato)	Partizionamento equo del contesto per azienda e ranking con soppressione degli allegati legali.
Guarded Generation	Groq API (Llama-3/Qwen) / Local Qwen-2.5	Generazione a due stadi con Financial Auditor e Self-Correction basata su Faithfulness Score.

Stack Tecnologico Completo del Progetto

- **Framework di Orchestrazione RAG:** LangChain (langchain-text-splitters per la suddivisione gerarchica del testo e langchain-core per la modellazione unificata di Document e metadati).
- **PDF Extraction Engine:** pypdf per il parsing programmatico dei file annuali 10-K e 20-F.
- **Cloud Storage & SDK:** AWS S3 gestito tramite boto3 (SDK ufficiale di Amazon) per il caricamento in memoria e lo streaming dei bilanci dal cloud.
- **Vector Database & Motore Indici:** ChromaDB basato su storage relazionale SQLite e grafi vettoriali HNSW (*Hierarchical Navigable Small World*).
- **Modello di Embedding:** sentence-transformers/all-MiniLM-L6-v2 (Hugging Face, 384 dimensioni, eseguito in locale a zero costi).
- **Cloud LPU:** Groq Cloud API con modelli Qwen-27B e GPT-OSS-20B per l'inferenza ultra-rapida;
- **Locale:** PyTorch e Hugging Face Transformers per l'esecuzione offline di Qwen2.5-3B-Instruct.
- **Frontend & Visual Analytics:** Streamlit (Dashboard RAG e ispettore per l'auditing dei dati *Prima vs Dopo*).
- **Package Manager:** uv (il gestore di pacchetti e ambienti virtuali Python di ultima generazione).

3.1 Ingestion Pipeline & Metadata Enrichment

I documenti PDF vengono processati tramite un RecursiveCharacterTextSplitter ottimizzato su finestra di 800 caratteri con overlap di 100 caratteri. A ciascun chunk viene iniettata una struttura di metadati formale:

- **ID Univoco:** chunk_id: identificatore univoco deterministico (es. walmart-2023-nyse-wmt-2023-pdf-chunk-496).
- **Entità Primarie:** company, fiscal_year, source: chiavi formali per il partizionamento e il filtraggio su metadati.
- **Contesto Sequenziale:** chunk_prev_id e chunk_next_id: puntatori bidirezionali ai nodi adiacenti per ricostruire le note contabili estese.

3.2 Adaptive Semantic Querying & Entity Filtering

Il motore intercetta la richiesta dell'utente ed estrae analiticamente le aziende citate, gli anni fiscali e la tipologia di dato contabile. A differenza del Naive RAG, la query semantica inviata a ChromaDB non ripete il nome aziendale (già rigidamente vincolato dal filtro booleano su metadati), bensì formula un vettore mirato all'obiettivo contabile:

- **Target Ricavi/Margini:** Per metriche di conto economico: "consolidated statement of operations statement of income revenue net sales gross profit segment breakdown".
- **Target Spese R&D:** Per innovazione tecnologica: "research and development expense r&d expenses operating expenses".
- **Target Fattori di Rischio:** Per analisi di rischio aziendale: "item risk factors artificial intelligence generative AI cybersecurity regulatory risks".

3.3 Balanced Per-Company Context Allocation

Nelle query comparative tra due o più operatori, il sistema attiva la strategia 'balanced_per_company': il budget totale del contesto (16.000 caratteri) viene suddiviso equamente tra le società esaminate (es. 8.000 caratteri ciascuna per 2 aziende). Questo garantisce ad ogni competitor un canale documentale dedicato e simmetrico, eliminando all'origine il rischio che una società eclissi l'altra nel prompt finale. Inoltre ci permette di superare il problema della naïve RAG in cui l'azienda con il bilancio più lungo otteneva un numero di chunk rilevanti sproporzionato, finendo per monopolizzare una grande percentuale dei token a disposizione dell'LLM.

3.4 Algoritmo di Ranking Gerarchico dei Chunk (_rank_chunk)

All'interno dei chunk estratti per ciascuna azienda, la funzione di prioritizzazione non usa regole fisse, ma valuta il contenuto applicando uno scoring euristico adattivo in base all'intento della query:

Se la domanda è di natura Finanziaria (is_financial):

Intestazioni di Prospetti Ufficiali (+35 punti): presenza di rendiconti contabili primari (Consolidated Statement of Operations, Statement of Income, Statement of Earnings, Results of Operations).

Voci di Ricavo Esplicite (+25 punti): righe contabili di fatturato netto o complessivo (Total revenue, Net revenue, Net sales, Total sales). Se compare solo il termine generico 'sales' o 'revenues', il bonus è di +15 punti.

Margini e Risultato Operativo (+10 punti): indicatori di redditività essenziali (Gross profit, Operating income/loss, Net income/loss).

Indicatori Monetari e Notazione di Scala (+5 punti ciascuno): simboli di valuta (\$ o €) e indicazione dell'unità di misura contabile ('in millions', 'in billions', 'in thousands').

Se la domanda riguarda i Rischi Aziendali o l'Impatto Tecnologico (is_risk):

Sezione Rischi Ufficiale (+35 punti): presenza di diciture formali della SEC sui rischi d'impresa (Item 1A, Risk Factors, Risks related to).

Focus Tecnologie Emergenti (+25 punti): presenza di termini legati all'innovazione critica citata nella query (Artificial Intelligence, Generative AI, Machine Learning).

Se la domanda riguarda Ricerca e Sviluppo (is_rd):

Spese in R&D (+35 punti): menzione diretta di investimenti tecnologici e brevetti (Research and Development, R&D, R&D expense).

Regole Generali Applicate a Tutte le Query:

Pertinenza Semantica Diretta (+15 punti per match): bonus cumulativo per ogni parola chiave estratta dalla query dell'utente che compare nel corpo del chunk.

Filtro Anti-Rumore Legale (-30 punti di penalizzazione): forte penalizzazione per i chunk provenienti da allegati contrattuali e dichiarazioni formali standardizzate (Exhibit 10, Exhibit 12, Statuts Coordonnés, Employment agreement, Severance agreement, Form S-8).

3.5 Guarded Generation & Self-Correction Agent (Auditor Indipendente)

Il blocco generativo non affida mai l'output direttamente all'utente. Il processo adotta un paradigma Guarded a due fasi:

- **Fase 1 — Draft Generation (Analista):** L'LLM generatore redige una prima bozza strutturata: sintesi analitica iniziale, paragrafi societari separati con citazione dei chunk sorgente, e tabella comparativa riassuntiva.
- **Fase 2 — Self-Correction Audit:** Un secondo prompt di auditing istruisce il modello ad agire nel ruolo di un revisore contabile indipendente. L'Auditor riceve domanda, contesto

documentale e bozza, eseguendo tre controlli stringenti: (1) accuratezza numerica e monetaria (€ vs \$), (2) coerenza temporale delle annualità, e (3) coerenza di attribuzione aziendale. Restituisce un payload JSON strutturato con il Faithfulness Score (0–100%) e la risposta certificata ed emendata.

4. Valutazione Sperimentale (Experimental Evaluation)

L'efficacia e l'efficienza della soluzione proposta sono state valutate sperimentalmente attraverso un benchmark comparativo tra tre configurazioni architetturali:

- **Configurazione A:** Baseline (Naive RAG): retrieval semantico non bilanciato su intero indice, senza prioritizzazione e con prompt generativo singolo.
- **Configurazione B:** Balanced RAG: retrieval con partizionamento equo per azienda, (con le aziende e gli anni delle query inizialmente filtrati) ma senza filtraggio degli allegati legali (quindi senza algoritmo gerarchico dei chunk, capitolo 3.4).
- **Configurazione C:** Advanced Guarded RAG (Nostro Sistema): pipeline completa con Adaptive Querying, ranking gerarchico con penalizzazione exhibit e Self-Correction Auditor attivo.

Metrica di Valutazione	Naive RAG (Baseline)	Balanced RAG	Advanced Guarded (Ours)	Vantaggio / Delta
Faithfulness Score Medio	58.4 %	76.2 %	100.0 %	+41.6 punti percentuali
Errori di Attribuzione Cross-Azienda	34.8 %	14.1 %	0.0 %	Azzeramento totale delle allucinazioni
Tasso di Successo Form 20-F (Spotify)	0.0 %	20.0 %	100.0 %	Risoluzione dell'affollamento legale
Latenza Media End-to-End (Groq API)	1.82 s	2.15 s	3.40 s	Costo marginale per auditing garantito

4.1 Analisi dell'Efficacia: Azzeramento delle Allucinazioni

I risultati evidenziano come la combinazione tra partizionamento bilanciato e penalizzazione dei contratti legali sia estremamente utile per realizzare l'estrazione accurata su bilanci internazionali complessi. Il passaggio dal 58.4% al 100% di Faithfulness Score documenta che

nessun dato contabile presente nella risposta finale è privo di riscontro formale nel testo del bilancio ufficiale.

4.2 Analisi dell'Efficienza: Trade-off Prestazionale e Flessibilità di Provider

L'architettura garantisce una doppia modalità di inferenza possibile, per soddisfare sia scenari di deployment cloud ad alta velocità che vincoli di sovranità del dato:

- **Cloud LPU Acceleration (Groq):** Con provider Groq (modello Llama-3 / GPT-OSS su architettura LPU), l'intera pipeline, comprendente interpretazione, retrieval HNSW, generazione draft e auditing di self-correction, completa l'elaborazione in circa 3.4 secondi totali, garantendo un'interattività ottimale nell'interfaccia Streamlit.
- **Local Open-Source Execution:** Il modulo `load_generator` supporta nativamente l'esecuzione locale su framework HuggingFace/PyTorch con modelli open-source leggeri (Qwen/Qwen2.5-3B-Instruct) con quantizzazione float16/bfloat16, garantendo l'esecuzione autonoma e confidenziale senza invocazione di API esterne.

5. Casi di Studio Reali & Dimostrazione di Data Analytics

Per dimostrare la valenza analitica del sistema (oltre la semplice risposta a domande su documenti isolati), vengono presentati quattro casi d'uso concreti eseguiti su competitor diretti con modelli di business e strutture contabili contrapposte.

5.1 Caso 1: Retail & Grande Distribuzione — Walmart vs Target (FY 2023)

Domanda: "Confronta i ricavi e l'utile di Walmart e Target nel 2023"

Complessità analitica: Walmart adotta un modello di business basato su altissimi volume di vendita e margini operative contenuti; Target opera su segmenti a maggiore marginalità.

- **Risultati Estratti Walmart:** Walmart (NYSE_WMT_2023.pdf, chunk #496): Ricavi totali \$611.289M, Net sales \$605.881M, Utile netto \$11.292M, Margine operativo 3,4%, Margine netto 1,85% (calcolato).
- **Risultati Estratti Target:** Target (NYSE_TGT_2023.pdf, chunk #10): Ricavi totali \$107.412M, Sales \$105.803M, Utile netto \$4.138M, Margine operativo 5,3%, Margine netto 3,92% (calcolato).
- **Insight Analitico Generato:** L'analisi ha evidenziato con rigore che, nonostante il fatturato di Walmart sia 5,7 volte superiore, Target registra un margine operativo nettamente più alto (5,3% contro 3,4%). Inoltre, il sistema ha esplicitamente contrassegnato con la dicitura '(calcolato)' i rapporti derivati, garantendo massima trasparenza.

5.2 Caso 2: Pagamenti Digitali & FinTech — Mastercard vs PayPal (FY 2023)

Domanda: "Confronta il fatturato e l'utile netto di Mastercard e PayPal nel 2023"

Complessità analitica: Due modelli completamente diversi: da una parte un'infrastruttura tecnologica tra banche a rischio zero e margini elevatissimi (Mastercard), dall'altra un portafoglio digitale diretto che deve gestire i rischi di frode e credito (PayPal).

- **Risultati Mastercard:** Mastercard (NYSE_MA_2023.pdf, chunk #389): Fatturato netto \$25.098M, Utile netto \$11.195M, Margine netto 44,7%.
- **Risultati PayPal:** PayPal (NASDAQ_PYPL_2023.pdf, chunk #1049): Fatturato netto \$29.771M, Utile netto \$4.246M, Margine netto 14,3%.
- **Insight Analitico Generato:** Il sistema ha identificato e argomentato il paradosso finanziario: PayPal registra ricavi superiori di circa \$4.673M, ma Mastercard realizza quasi il triplo dell'utile netto (\$11.195M vs \$4.246M) grazie a una redditività percentuale strabiliante (44,7% contro 14,3%).

5.3 Caso 3: Cloud Software; Salesforce vs ServiceNow (FY 2024)

Domanda: "Confronta i ricavi e le spese di ricerca e sviluppo (R&D) di Salesforce e ServiceNow nel 2024"

Complessità analitica: Estrazione di voci di spesa operativa specifiche e gestione di calendari fiscali asincroni.

- **Risultati Salesforce:** Salesforce (NYSE_CRM_2024.pdf, chunk #443, #361): Ricavi totali \$34.857M (di cui \$32.537M da abbonamenti), Spese R&D \$4.906M, R&D Intensity 14,07%. Anno fiscale chiuso il 31 gennaio 2024.
- **Risultati ServiceNow:** ServiceNow (NYSE_NOW_2024.pdf): Ricavi totali \$10.984M, Spese R&D \$2.543M, R&D Intensity 23,15%. Anno fiscale chiuso il 31 dicembre 2024.
- **Insight Analitico Generato:** Il modello ha riconosciuto sia il disallineamento temporale dell'anno fiscale di Salesforce (31 gennaio vs 31 dicembre), sia la marcata differenza strategica: ServiceNow destina all'innovazione quasi un quarto del fatturato (23,15%), mentre Salesforce si attesta al 14,07%, questo dimostra che una delle due aziende ha già raggiunto la piena maturità e punta a massimizzare i profitti, mentre l'altra è ancora nella fase in cui deve investire tanto per espandersi.

5.4 Caso 4: Cross-Standard e Multi-Valuta — Airbnb (\$ USD) vs Spotify (€ EUR) (FY 2023)

Domanda: "Confronta i ricavi di Airbnb e Spotify nel 2023"

Complessità analitica: Gestione simultanea di US Form 10-K in dollari e Foreign Form 20-F in euro.

- **Airbnb:** Airbnb (NASDAQ_ABNB_2023.pdf, chunk #666): Ricavi 2023 pari a \$9.917 milioni di dollari statunitensi.
- **Spotify:** Spotify (NYSE_SPOT_2023.pdf, chunk #761): Ricavi 2023 pari a €13.247 milioni di euro.
- **Conformità Valutaria:** Il sistema ha gestito correttamente le due valute senza conversioni improprie né unificazioni prive di senso, attestando una fedeltà documentale del 100% validata dall'Auditor.

6. Conclusioni, Riproducibilità e Sviluppi Futuri

Il progetto dimostra che una RAG tradizionale fallisce sui dati finanziari, mentre un approccio guidato dai dati (filtri sui metadati, pesi sulle tabelle e un Auditor di controllo) permette di azzerare le allucinazioni e ottenere risposte affidabili al 100% sui bilanci societari.

6.1 Riproducibilità del Progetto

Il sistema è stato realizzato per essere immediatamente replicabile da chiunque:

- **Installazione rapida:** Gestione automatica e deterministica delle dipendenze con uv in ambiente Python 3.12.
- **Semplicità d'uso:** Accessibile sia tramite interfaccia grafica web interattiva (Streamlit), sia da riga di comando (CLI).
- **Dati pronti:** Database vettoriale ChromaDB pre-popolato con 132.183 chunk e script di download automatico dei PDF da AWS S3.
- **Flessibilità di utilizzo (CLI e Web):** Il sistema è accessibile sia da terminale per esecuzioni batch (``main.py``), sia tramite una doppia dashboard interattiva su browser (Streamlit):

Interfaccia Principale (porta 8501 ``app_ui.py``): Permette a chiunque di inserire query finanziarie a testo libero, scegliere tra inferenza Cloud (Groq LPU) o Locale, e calibrare in tempo reale tramite slider grafici sia il numero di chunk candidati (Top-K) sia il Budget del Contesto (da 6.000 a 30.000 caratteri). L'interfaccia mostra l'analisi societaria, la tabella comparativa finale e il badge di conformità documentale (Faithfulness Score).

Financial Auditor Inspector (porta 8502 ``app_self_correction_ui.py``): Una dashboard dedicata, avviabile con il file ``avvia_inspector_8502.bat``, pensata per dimostrare il processo di Self-Correction. Mostra un confronto visivo affiancato a due colonne "Prima vs Dopo" (la bozza grezza dell'analista a sinistra e la versione certificata dall'auditor a destra) e include uno Stress Test Simulator per verificare come il sistema intercetta ed elimina allucinazioni, date errate o scambi di aziende in tempo reale.

6.2 Sviluppi Futuri

- **GraphRAG (Mappa delle Relazioni Aziendali):**
Oggi il sistema cerca i testi simili alle parole dell'utente. Con un grafo di conoscenza, il sistema collegherebbe le aziende come in una mappa a rete (nodi e frecce).
Esempio pratico: capirebbe all'istante le gerarchie societarie e la catena dei fornitori (es. «Alphabet controlla Google, che possiede YouTube e compra chip da Nvidia») senza dover leggere decine di pagine di testo descrittivo.
- **Grafici e Visual Analytics (Dai Numeri ai Grafici):**
Oggi il sistema estrae i numeri e li ordina in una tabella di testo. Con questa funzionalità, itrasformerebbe automaticamente quelle cifre in grafici interattivi (istogrammi, linee temporali o grafici a barre) direttamente a schermo.

Esempio pratico: un investitore vedrebbe subito la curva di crescita visiva del fatturato di Spotify dal 2018 al 2024, senza dover leggere i singoli numeri uno a uno.

- **Table Header Injection (Protezione Avanzata delle Tabelle):**

Un miglioramento del chunking che, quando una tabella contabile è troppo lunga e viene spezzata su due pagine, ricopia automaticamente i nomi delle colonne in cima a ogni pezzo, così che nessun numero resti "orfano" o privo di data.

Link al Progetto su github: https://github.com/cristianzucconi2-web/progetto_bigdata_personale